Visualisation et Analyse de Données

SED-1516 A00

Livrable 3

Variations des concentrations de polluants atmosphériques dans des villes urbaines et rurales de l'Ontario (2015-2024)

Groupe 5

Dashinee M Parmanum

Sarah F. Ouangré

Université d'Ottawa

Date de soumission : 23 mars 2026

Contribution dans le Groupe 5

Tâches	Dashinee	Sarah	AI	Total
Page titre	50%	50%	0%	100%
Description des tâches	100%	0%	0%	100%
Introduction	0%	100%	0%	100%
Connexion et modélisation des données	75%	25%	0%	100%
Visualisation des données	66.6%	33.3%	0%	100%
Limites et difficultés de Power BI	66.6%	33.3%	0%	100%
Rapports et analyses futurs	0%	100%	0%	100%
Références et annexe	50%	50%	0%	100%
Présentation et mise en forme du rapport	50%	50%	0%	100%
Signature	dmp	*OSF*		

Description des tâches

Tâche 1 : Page titre

Responsable : Dashinee et Sarah

Description : Remplissage du modèle de page titre avec le numéro du livrable, le titre du projet, nos noms, nos numéros étudiants et la date de soumission.

Tâche 2 : Description des tâches

Responsable : Dashinee et Sarah

Description : Fournir de l'information sur chaque tâche et définir la ou les personnes responsables pour une contribution équitable des membres.

Tâche 3 : Introduction

Responsable : Sarah

Description : Présentation des objectifs du tableau de bord, l'importance de Power BI et la liste des parties prenantes.

Tâche 4 : Connexion et modélisation des données

Responsable : Dashinee et Sarah

Description : Importation des jeux de données dans Power BI et présentation du concept de modélisation des données, incluant la création de relations entre les tables.

Tâche 5 : Visualisation des données

Responsable : Dashinee et Sarah

Description : Création des 3 pages du tableau de bord interactif.

Tâche 6 : Limites et difficultés de Power BI

Responsable : Dashinee et Sarah

Description : Discussion des limites rencontrées et des améliorations possibles.

Tâche 7 : Rapports et analyses futurs

Responsable : Sarah

Description : Discussion des techniques avancées souhaitées et de l'application possible de l'analyse des séries temporelles dans un futur rapport.

Tâche 8 : Références et annexe

Responsable : Dashinee et Sarah

Description : Ajout de la liste des références et rédaction de l'annexe.

Tâche 9 : Présentation et mise en forme du rapport

Responsable : Dashinee et Sarah

Description : Vérification du rapport pour éliminer les fautes d'orthographe et de grammaire. Organisation et mise en forme du rapport pour rendre la structure plus fluide.

Table des Matières

1. Introduction 4
2. Connexion et modélisation des données 4
2.1. Connexion des données 4
2.2. Modélisation des données 5
3. Visualisation des données 5
3.1. Survol : Qualité de l'air en Ontario - Tendances de 2015 à 2024 5
3.2. Villes urbaines vs rurales : Comparaison Urbain vs Rural - Moyennes de 2015 à 2024 7
3.3. Avant vs après pandémie : Impact de la Pandémie de COVID19 9
4. Limites et difficultés de Power BI 13
5. Rapports et analyses futurs 14
Références 15
Annexe 16

Table des Figures

Figure 1 : Page 1 – Survol 6
Figure 2 : Page 2 – Villes urbaines vs rurales 7
Figure 3 : Page 2 – Tooltip pour le graphique à barres montrant Minimum et Maximum également 8
Figure 4 : Page 2 – Tooltip pour la carte montrant le Minimum, Maximum et Polluant également 8
Figure 5 : Page 3 – Impact de la pandémie de COVID19 10
Figure 6 : Page 3 – Différence dans la qualité de l'air entre 2019 et 2020 11
Figure 7 : Page 3 – Différence dans la concentration de NOx entre 2019 et 2020 11
Figure 8 : Page 3 – Différence dans la concentration de NOx entre 2019 et 2020 dans les milieux urbains 12
Figure 9 : Page 3 – Différence dans la concentration de NOx entre 2019 et 2020 dans les milieux urbains 12

1. Introduction

La création des tableaux de bord vise à fournir une synthèse visuelle des tendances temporelles et spatiales des polluants (NO, NO2, NOx, PM2.5 et O3) dans 6 villes de la province de l'Ontario entre 2015 et 2024. Ces analyses comparent les milieux ruraux et urbains tout en illustrant l'impact de la pandémie de COVID-19 sur la qualité de l'air. Ils facilitent l'interprétation rapides de données, la validation des hypothèses et une communication claire des résultats.

Dans le contexte de notre étude, Power BI permet une analyse interactive de grands nombres de données environnementales. Cela inclue des analyses géospatiales et temporelles pertinentes. Il favorise une meilleure surveillance de la qualité de l'air et soutient l'évaluation des politiques environnementales. Transformer des données complexes en récit visuel accélère la prise de décision pour les différentes parties prenantes.

La présente étude s'adresse à une variété de parties prenantes. Trois tableaux de bord ont été créés pour répondre à nos trois hypothèses. Le premier présente un survol général des données pour identifier les tendances des concentrations de polluants sur une période de dix années. Cette information est particulièrement utile pour les décideurs gouvernementaux et le grand public. Le deuxième tableau de bord montre les différences dans la qualité d'air entre les milieux urbains et les villes ruraux. Cela est majoritairement utilise pour les planificateurs municipaux, les agences de transports et les chercheurs en environnement. Le troisième tableau présente les effets de la pandémie sur la qualité de l'ai et est en davantage utile pour les chercheurs en santé publique et les gouvernements (fédéral, provincial, et municipal).

2. Connexion et modélisation des données

2.1. Connexion des données

Power BI offre une grande flexibilité dans l'import des données depuis diverses sources tels que les fichiers CSV, Excel ou les bases de données relationnelles comme SQL Server. Dans notre cas, les données ont été importées à partir d'un fichier Excel nommé *data_livrable3.xlsx*. Ce fichier est une version ajustée et nettoyée du fichier utilisé pour la livrable 2. Ce fichier Excel initial a été créé en important et combinant les multiples fichiers CSV téléchargés sur le site du gouvernement de l'Ontario.

À partir d'un rapport Power BI vierge, l'option « Import data from Excel» a été utilisée afin de sélectionner la source Excel et charger la feuille contenant les données. Une fois les données importées, la fonction « Transform Data » a été utilisée afin d'ouvrir l'éditeur Power Query et vérifier la structure du jeu de données. Cette étape a permis de confirmer la présence des en-têtes de colonnes et de vérifier l'absence de lignes ou de colonnes vides avant de charger les données dans Power BI pour la création des visualisations.

2.2. Modélisation des données

La modélisation des données dans Power BI consiste à créer des relations logiques entre plusieurs tables afin de permettre des analyses croisées et des visualisations interactives. Elle permet notamment de relier des informations provenant de sources différentes en utilisant des clés communes. Une bonne modélisation facilite la création de mesures et de rapports dynamiques et réduit le risque d'erreurs dans les calculs.

Dans notre cas, toutes les données sont contenues dans une seule feuille Excel. Il aurait été possible de séparer la page principale en tables de faits et tables de dimensions selon un schéma en étoile pouvoir créer des connexions entre les tableaux [1]. Toutefois, après concertation avec le professeur, il nous a été informé que cela n'était pas nécessaire.

3. Visualisation des données

Nous avons créé un tableau de bord Power BI composé de trois pages : Survol, Villes urbaines vs rurales, Avant vs après pandémie. Chaque page permet de visualiser les données sous différents angles et avec différents types de graphiques, afin de rendre l'analyse plus claire et interactive.

3.1. Survol : Qualité de l'air en Ontario - Tendances de 2015 à 2024

Cette page fournit un aperçu général des tendances de la qualité de l'air dans toutes les villes. Les utilisateurs peuvent visualiser l'évolution des concentrations des différents polluants au fil des années.

Les éléments interactifs et visuels incluent :

- Slicers : pour filtrer par polluant (boutons - sélection multiple possible) et par station (boutons - sélection multiple possible).

- Graphique linéaire : évolution des moyennes mensuelles sur 10 ans, avec axes et légendes clairement étiquetés.
- Cartes : affichage des valeurs globales Minimum, Moyenne et Maximum.
- Graphique à barres : comparaison des polluants par ville.

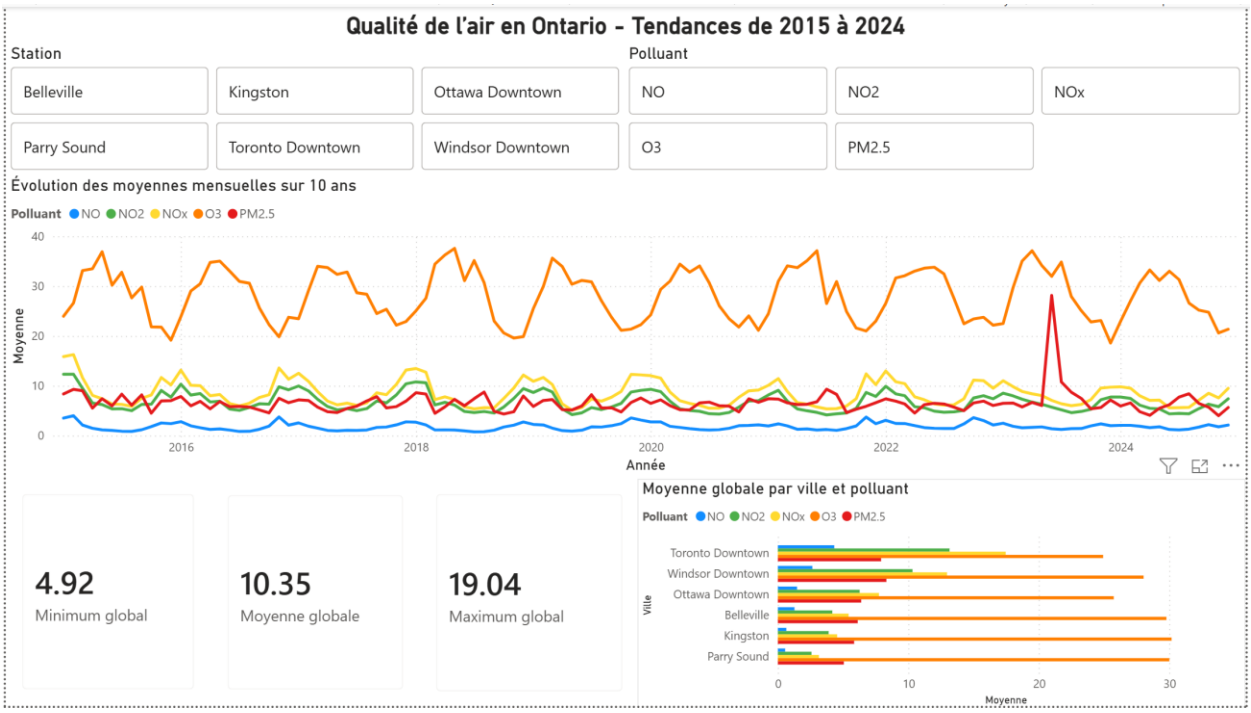

Figure 1 : Page 1 – Survol

Tous les visuels ont été formatés pour être clairs et lisibles, et permettent une navigation interactive via les slicers afin que les utilisateurs puissent explorer les données facilement. Une palette de couleurs cohérente a également été utilisée pour faciliter la compréhension des informations.

Interprétation des résultats

Le graphique linéaire montre que les concentrations de la plupart des polluants restent relativement constantes sur les 10 années. Cependant, une forte saisonnalité est visible : l'O3 présente des variations très marquées avec un pic clair en été, tandis que NO2, NOx et PM2.5 montrent une saisonnalité plus modérée. Le polluant NO est celui qui varie le moins au cours de l'année. Le pic exceptionnel de PM2.5 observé en juin 2023 est directement lié aux feux de forêt records qui ont affecté le Canada cette année-là.

3.2. Villes urbaines vs rurales : Comparaison Urbain vs Rural - Moyennes de 2015 à 2024

Cette page permet de comparer les niveaux de pollution entre les zones urbaines et rurales en se basant sur les moyennes des différents polluants de 2015 à 2024. Cette comparaison met en évidence qu'il existe effectivement une différence entre les niveaux de pollution des zones urbaines et rurales, offrant ainsi une vue plus détaillée par catégorie de ville et par polluant.

Les éléments interactifs et visuels incluent :

- Slicers : pour filtrer par polluant (boutons, sélection unique) et par date (slider).
- Carte avec bulles : la taille des bulles reflète la moyenne des concentrations de pollution.
- Graphique à barres : comparaison par catégorie (Urbain/Rural) et par polluant.
- Treemap : visualisation des valeurs moyennes par catégorie.

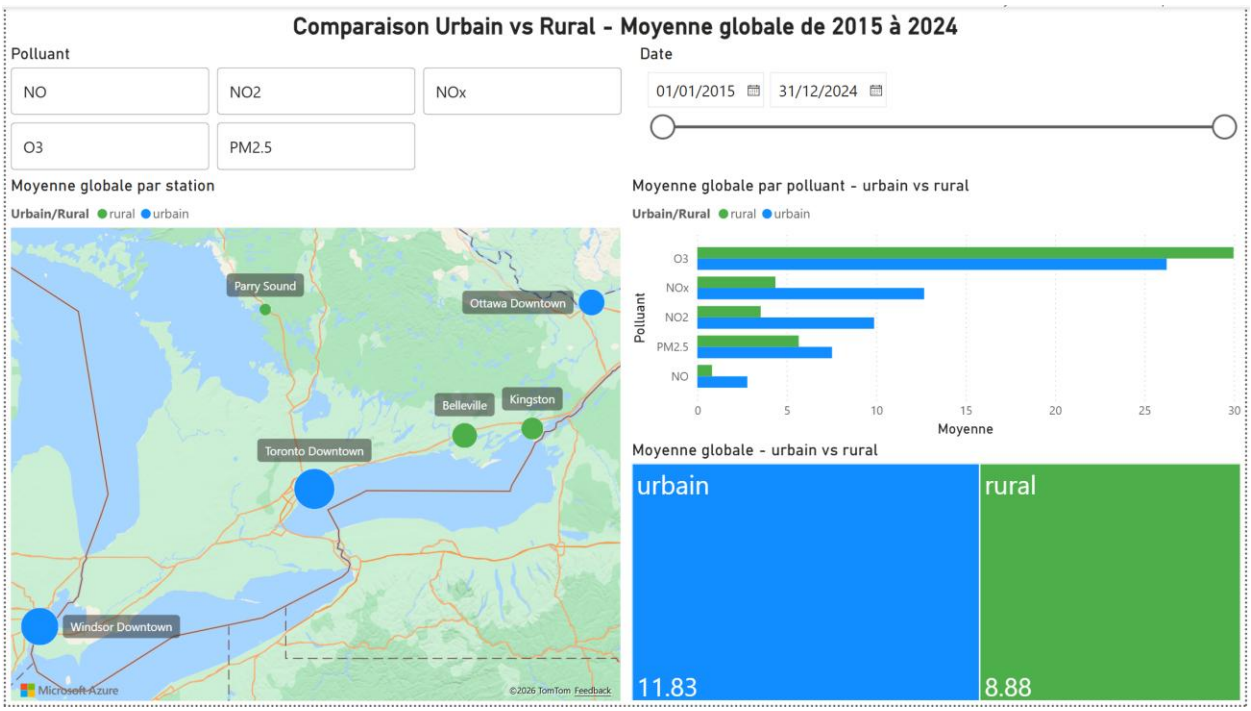

Figure 2 : Page 2 – Villes urbaines vs rurales

Visualisations avancées

Des info-bulles personnalisées (Custom Tooltips) ont ajoutées à la carte et au graphique à barres pour afficher la valeur minimale, maximale et le polluant lors du survol d'un élément.

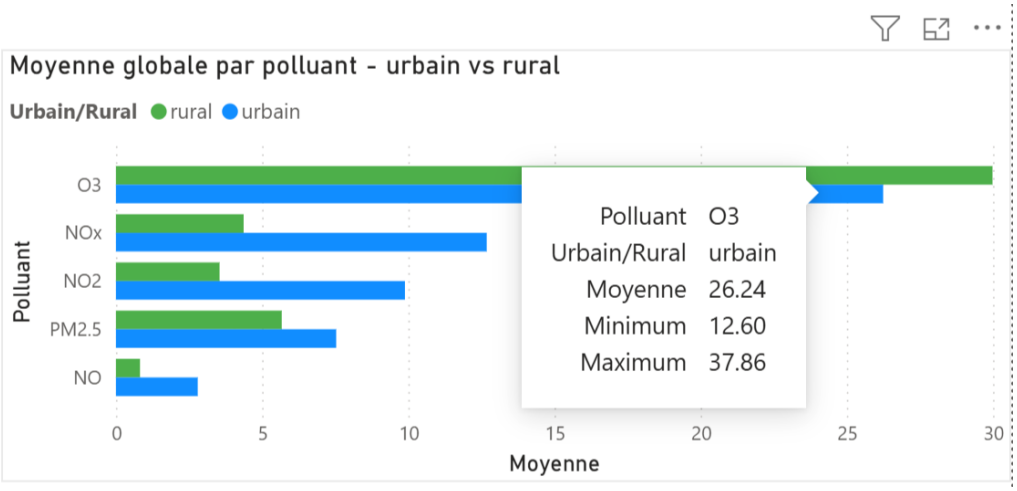

Figure 3 : Page 2 – Tooltip pour le graphique à barres montrant Minimum et Maximum également

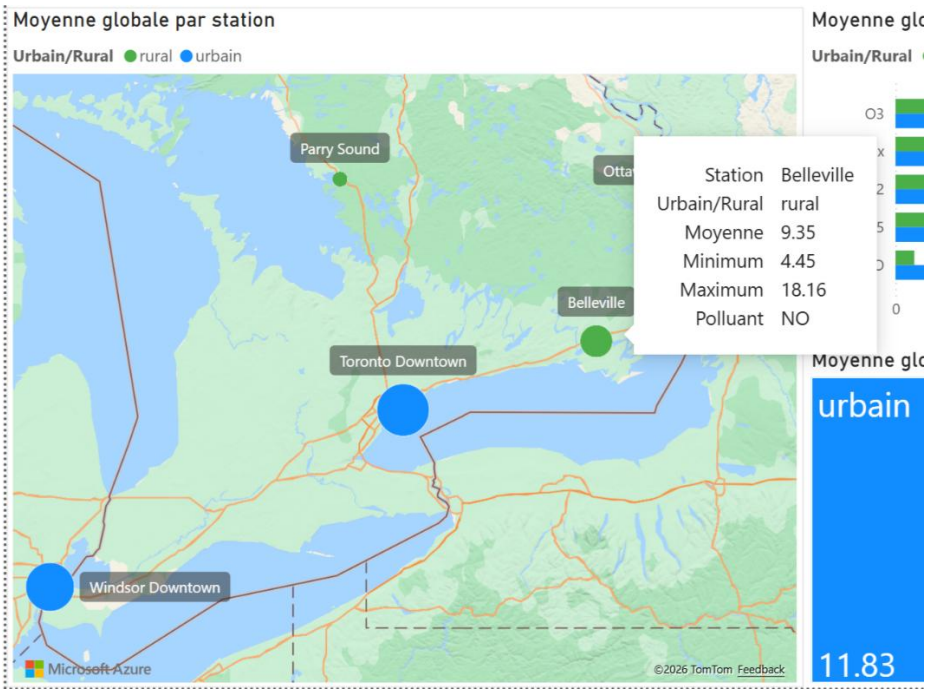

Figure 4 : Page 2 – Tooltip pour la carte montrant le Minimum, Maximum et Polluant également

Cette page a été principalement réalisée avec un focus sur le formatage, les filtres interactifs et la création des info-bulles personnalisées afin de rendre les données plus compréhensibles et explorables. Une palette de couleurs cohérente a été utilisée, avec du bleu pour les zones urbaines et du vert pour les zones rurales, afin de faciliter la distinction visuelle et la compréhension des informations.

Interprétation des résultats

Les visualisations montrent que les polluants de trafic sont nettement plus élevés en zone urbaine: NO (Moyenne globale sur 10 ans : 2.80 vs 0.82), NO2 (Moyenne globale sur 10 ans : 9.88 vs 3.54) et NOx (Moyenne globale sur 10 ans : 12.68 vs 4.37). Le PM2.5 est aussi plus élevé en urbain (Moyenne globale sur 10 ans : 7.53 vs 5.67), bien que la différence soit moins marquée. En revanche, l'O3 est légèrement plus élevé en rural (Moyenne globale sur 10 ans : 29.98 vs 26.24), probablement à cause d'une moindre titration par les oxydes d'azote en ville.

Ces résultats confirment clairement notre hypothèse : les zones urbaines subissent une pollution plus importante liée au trafic et à l'activité humaine.

3.3. Avant vs après pandémie : Impact de la Pandémie de COVID19

Cette page permet de visualiser l'impact de la pandémie de COVID-19 dans la concentration de polluants atmosphériques. Les données ont divisé en 4 périodes : 2015-2018 (pré pandémie), 2019 (juste avant), 2020 (pandémie et confinement), 2021-2024 (post pandémie). Ces analyses montrent que la pandémie a généralement causé une baisse des concentrations de polluants dans les villes urbaines et rurales.

Les éléments interactifs et visuels incluent :

- Slicers : 4 différents pour permettre la filtration par type de villes, par ville, par périodes et par polluants. Les sélections multiples sont possibles pour ces slicers.
- Carte : Cette carte permet d'afficher la valeur médiane et la concentration moyenne des polluants. Elle affiche aussi la variation entre la concentration moyenne entre 2019 et 2020, mesure générer par code DAX (voir annexe).
- Clustered Bar Chart : La figure montre la concentration moyenne de chaque polluant par période.
- Line Chart : Elle présente la concentration moyenne dans les milieux urbains et ruraux par année.

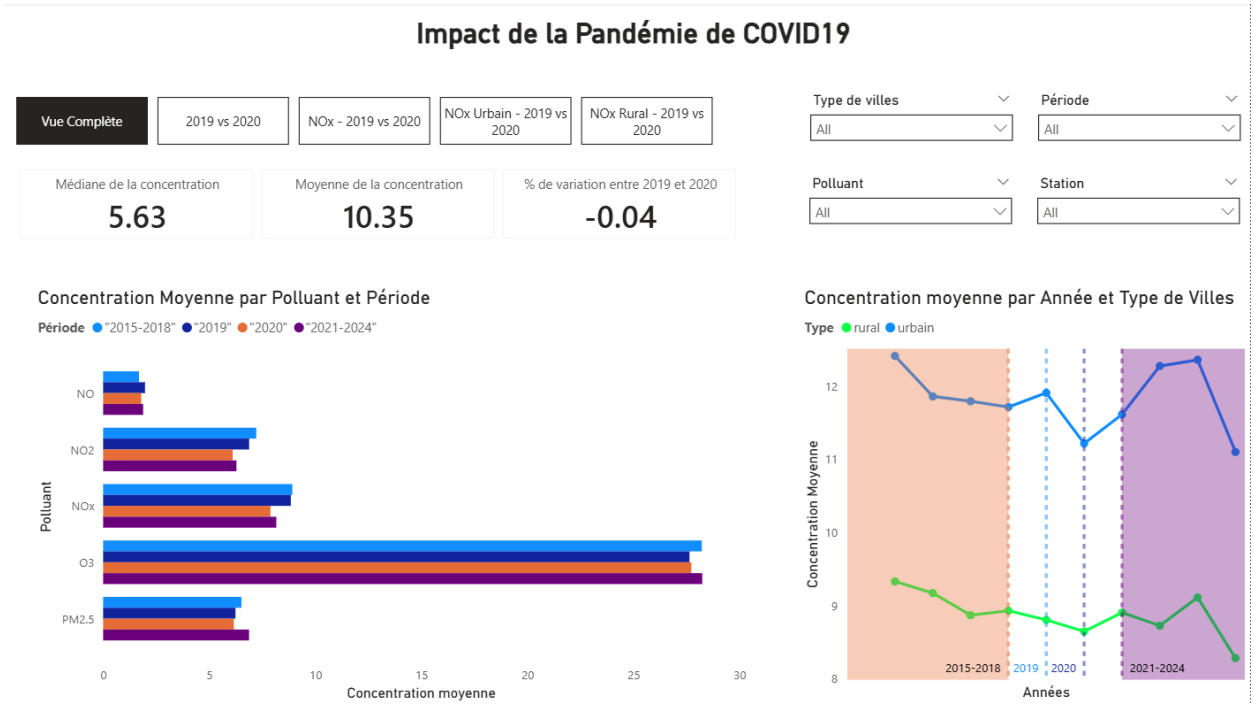

Figure 5 : Page 3 – Impact de la pandémie de COVID19

Interprétation des résultats

La page montre en général une diminution de 0.04% des concentrations de polluants entre 2019 et 2020. En dehors des concentrations de O3, les concentrations des autres polluants dans le graphique à barres montrent une diminution des concentrations. Le graphique linéaire montre des tendances similaires. L'on remarque que la baisse est plus prononcée dans les milieux urbains que dans les milieux ruraux. De manière global, les illustrations indiquent que la pandémie a conduit à une amélioration de qualité de l'air.

Visualisations avancées

Des signets (bookmarks) ont été intégrées pour permettre une navigation rapide entre les différents scénarios (Vue Complète, 2019 vs 2020, NOx – 2019 vs 2020, NOx Urbain – 2019 vs 2020 et NOx Rural – 2019 vs 2020). Cela offre une expérience plus interactive et ciblée pour analyser les impacts de la pandémie.

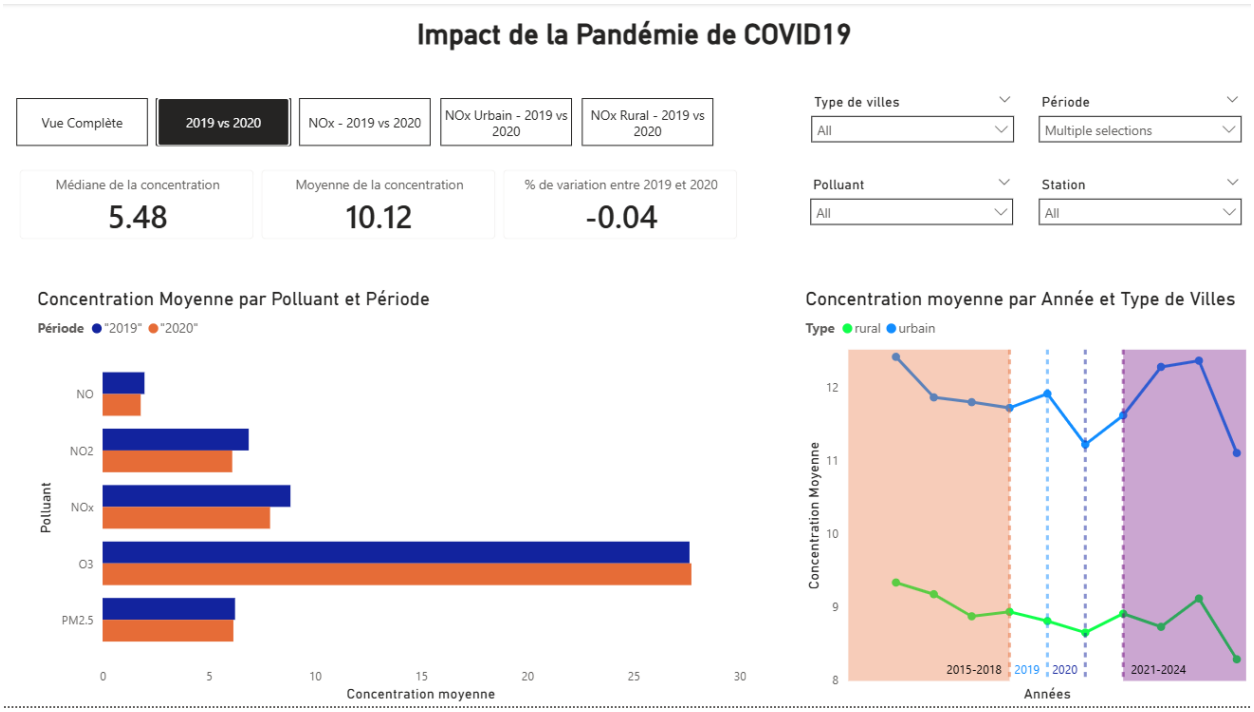

Figure 6 : Page 3 – Différence dans la qualité de l'air entre 2019 et 2020

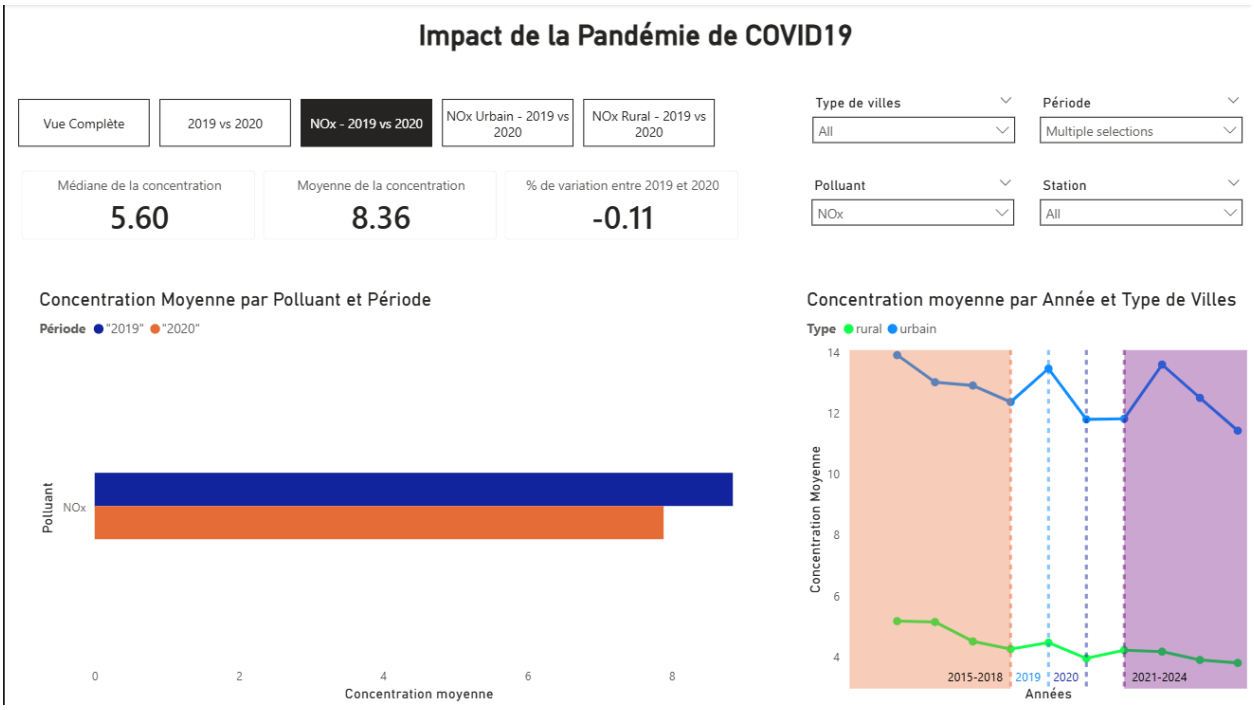

Figure 7 : Page 3 – Différence dans la concentration de NOx entre 2019 et 2020

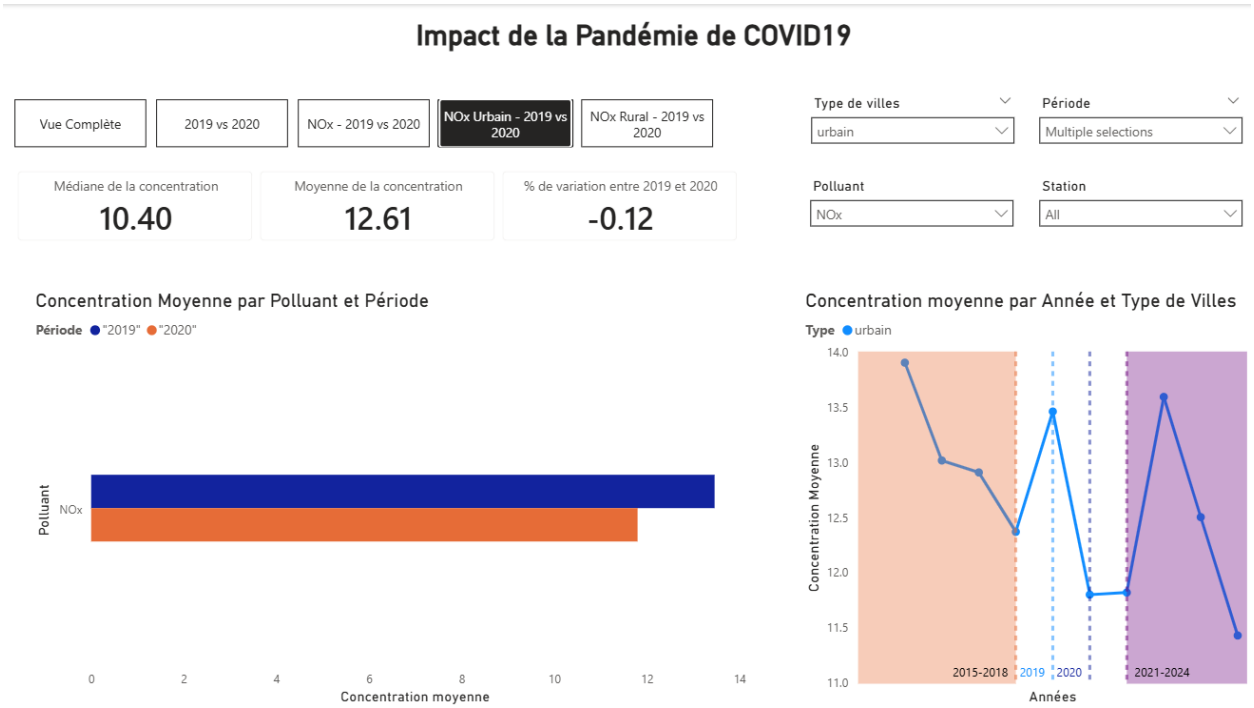

Figure 8 : Page 3 – Différence dans la concentration de NOx entre 2019 et 2020 dans les milieux urbains

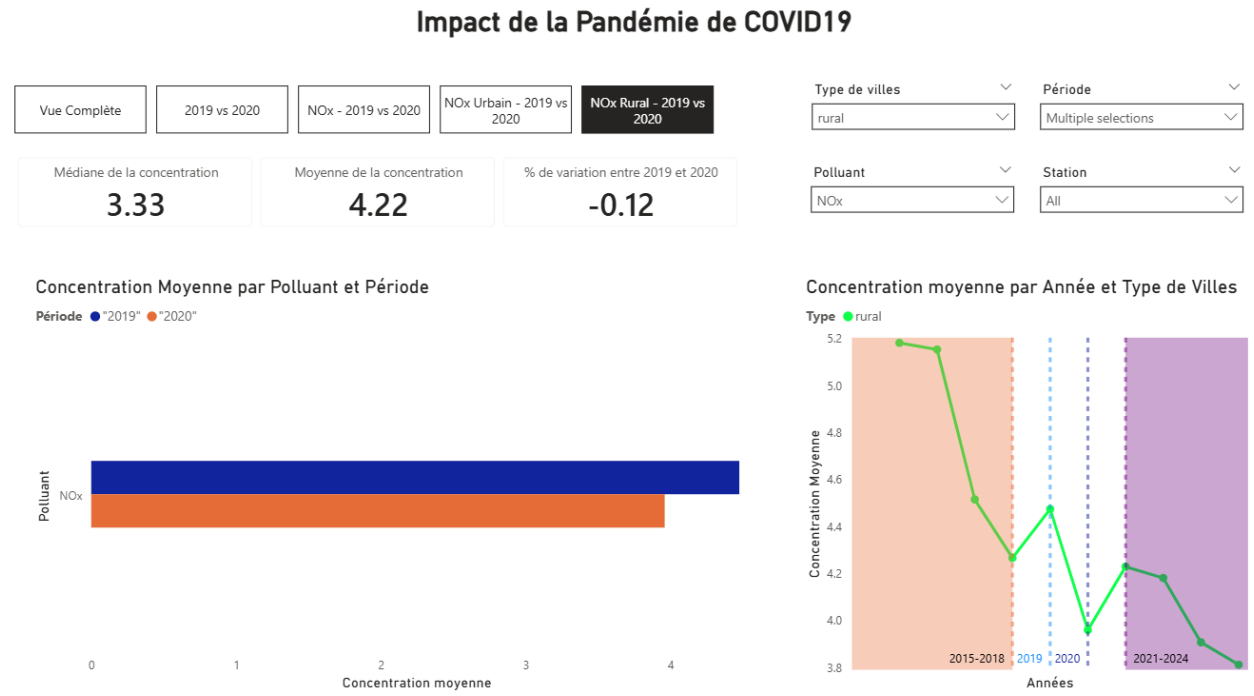

Figure 9 : Page 3 – Différence dans la concentration de NOx entre 2019 et 2020 dans les milieux urbains

En isolant des sous catégories spécifiques (tous les polluants, NOx seul, NOx urbain et NOx rural) on remarque les signets favorisent une détection des variations plus fines. Réduire le niveau d'agrégation dans le cas montre une plus grande diminution des concentrations entre 2019 et 2020, ce qui reflète les effets à petite échelle de la pandémie.

4. Limites et difficultés de Power BI

Power BI est un outil puissant pour la visualisation et l'analyse des données, mais certaines limitations ont été rencontrées :

- Page 1 - Survol : les cartes et autres visualisations interagissent avec les slicers, ce qui signifie que si aucun polluant n'est sélectionné ou si plusieurs polluants sont choisis, les cartes affichent les valeurs globales (Minimum, Moyenne, Maximum) pour tous les polluants impliqués, ce qui peut rendre l'interprétation moins directe pour certaines analyses.
- Page 2 - Villes urbaines vs rurales : il n'a pas été possible de créer un box plot, car Power BI agrège automatiquement les valeurs (somme, moyenne, etc.) et ne permet pas de conserver les distributions individuelles nécessaires pour ce type de graphique. De plus, lorsque aucun polluant n'est sélectionné, le treemap affiche la moyenne pour tous les polluants, ce qui reflète le comportement des visualisations interactives avec les slicers.
- Page 3 - Avant vs après pandémie : En termes de limitations, Power BI ne permet pas de faire des tests statistiques pour évaluer que les différences sont significatives. Ainsi, cela limite la validation de l'effet de la pandémie.

Améliorations possibles

Plusieurs améliorations pourraient être apportées pour rendre le tableau de bord plus robuste et intuitif.

- Page 1 - Survol : les cartes KPI et le graphique en lignes pourraient bénéficier d'un comportement plus intelligent avec les slicers, par exemple en affichant un message « Sélectionnez un polluant » lorsque plusieurs polluants sont choisis simultanément.
- Page 2 - Villes urbaines vs rurales : un drillthrough vers une page détaillée par ville permettrait d'explorer les distributions individuelles sans surcharger la page principale.

- Page 3 - Avant vs après pandémie : Intégrer des données mensuelles ou hebdomadaires pourrait permettre une analyse plus précise. Cela peut être fait à travers l'insertion d'un drillthrough vers une autre page. L'utilisateur sera en mesure de cliquer sur une ville ou un polluant afin d'afficher davantage de détails comme les tendances mensuelles.

5. Rapports et analyses futurs

Pour le rapport final, nous désirons incorporer le drillthrough et le drilldown pour explorer avec plus de détails les données. Par exemple, nous aimerions évoluer d'une vue provinciale à une vue par types de villes et par villes. Nous voulons aussi être en mesure de faire des zooms temporels en passant des années, à des mois et enfin à des jours. L'analyse mentionne permettra d'isoler les effets de la saisonnalité en comparant les jeux de données surtout pour évaluer les effets de la pandémie. Nous pouvons aussi utiliser le volet analytique pour faire des prédictions sur les valeurs de concentrations dans le proche futur [2].

L'analyse de séries temporelles consiste à analyser l'évolution d'une variable au fil du temps pour identifier une tendance et des anomalies et aussi faire des prévisions [3]. Cette analyse s'applique directement à notre jeu de données mesurées car les polluants ont été mesurés quotidiennement sur une période de 10 ans. Une intégration plus avancée de l'analyse permettrait de projeter les tendances futures des concentrations et déterminer si les politiques environnementales produisent des effets mesurables à long terme.

Références

[1] Microsoft, “Découvrez le schéma en étoile et son importance pour Power BI - Power BI.” Accessed: Mar. 20, 2026. [Online]. Available: https://learn.microsoft.com/fr-fr/power-bi/guidance/star-schema

[2] Microsoft, “Utiliser le volet Analytique dans Power BI - Power BI.” Accessed: Mar. 21, 2026. [Online]. Available: https://learn.microsoft.com/fr-fr/power-bi/transform-model/desktop-analytics-pane

[3] Microsoft, “Effectuer une analyse de série chronologique - Training.” Accessed: Mar. 21, 2026. [Online]. Available: https://learn.microsoft.com/fr-fr/training/modules/perform-analytics-power-bi/6-time-series-analysis

Annexe

À partir du fichier *combined_cities.xlsx* utilisé dans le livrable 2, la feuille contenant les données de toutes les villes a été transformée afin de faciliter son utilisation dans Power BI.
Les étapes suivantes ont été réalisées dans Excel :

- La feuille originale a été copiée dans un nouveau fichier nommé *data_livrable3.xlsx*.
- Les colonnes correspondant aux statistiques « median » et « mode » ont été supprimées afin de conserver uniquement les valeurs moyenne, minimale et maximale.
- Dans Power Query, toutes les colonnes contenant les niveaux de polluants ont été « unpivotées » afin d'obtenir deux colonnes : Attribute et Value.
- La colonne Attribute a ensuite été séparée en deux variables : stat (mean, max, min) et Polluant (PM2.5, O3, NOx, NO2, NO).
- Les valeurs ont ensuite été « pivotées » afin d'obtenir les colonnes finales Moyenne, Maximum et Minimum chaque ligne.

La structure finale du jeu de données comprend les variables suivantes : Station, Urbain/Rural, Date, Year, Month, year+month, Polluant, Moyenne, Maximum, Minimum. Cette transformation permet de filtrer facilement les polluants dans Power BI et d'appliquer les slicers correctement dans les visualisations interactives.

Pour les pages 1 et 2, une copie dédiée *data_pg1&2.xlsx* a été utilisée afin d'éviter tout problème lié aux modifications sur *data_livrable3.xlsx*.

Pour la page 3, *data_livrable3.xlsx* a été à nouveau chargé séparément et transformé avec Power Query qui correspond au tableau data_covid. Ce tableau contient 11 colonnes : station, urbain/rural, data, year, month, year+month, polluant, Moyenne, maximum, minimum et période. L'ajout d'une colonne conditionnelle pour définir les quatre périodes (2015-2018, 2019, 2020 et 2021-2024) a été effectuée.

La mesure de la différence entre l'année 2019 et 2020 a été crée à partir du code DAX suivant :

```
% de changement entre 2019 et 2020 =
DIVIDE(
    CALCULATE(AVERAGE(data_covid[Moyenne]), data_covid[Year] = 2020) -
    CALCULATE(AVERAGE(data_covid[Moyenne]), data_covid[Year] = 2019),
    CALCULATE(AVERAGE(data_covid[Moyenne]), data_covid[Year] = 2019)
)
```